

Otonom Drone Filo Optimizasyonu: A, CSP ve Genetik Algoritma Tabanlı Çok-Katmanlı Yaklaşım

1. Doğukan Görür
Bilişim Sistemleri Müh.
Kocaeli Üniversitesi
Kocaeli, Türkiye
231307095@kocaeli.edu.tr

2. Melisa Ceylan
Bilişim Sistemleri Müh.
Kocaeli Üniversitesi
Kocaeli, Türkiye
191307022@kocaeli.edu.tr

3. Yusuf Perktas
Bilişim Sistemleri Müh.
Kocaeli Üniversitesi
Kocaeli, Türkiye
231307103@kocaeli.edu.tr

Özetçe—Bu çalışmada, otonom drone filoları için çok kriterli bir rota ve görev atama optimizasyonu problemi ele alınmaktadır. Lojistik ve kargo taşımacılığında "son kilometre" teslimat süreçlerini iyileştirmeyi hedefleyen bu sistem, teslimat öncelikleri, ağırlık kısıtları, batarya limitleri ve Yasak Uçuş Bölgeleri (YUB) gibi karmaşık kısıtları dikkate almaktadır. Python ile geliştirilen çözüm, Kısıt Tatmin Problemi (CSP) tabanlı ön atama, Genetik Algoritma (GA) ile küresel iyileştirme ve her teslimat için A* arama algoritmasıyla güvenli rota planlama aşamalarını içeren çok katmanlı bir yaklaşım sunmaktadır. Sistem ayrıca, batarya kullanımı ve rota verimliliği gibi temel performans göstergelerini (KPI) görselleştiren modüller içermektedir.

Anahtar Kelimeler—Otonom Drone, Filo Optimizasyonu, Rota Planlama, Görev Atama, Genetik Algoritma, Kısıt Tatmin Problemi, A* Algoritması, Yasak Uçuş Bölgeleri, Son Kilometre Teslimat, Çok Kriterli Optimizasyon

Abstract—In this paper, we consider a multi-criteria route and task assignment optimization problem for autonomous drone fleets. Aiming to improve "last mile" delivery processes in logistics and cargo transportation, this system considers complex constraints such as delivery priorities, weight constraints, battery limits, and No Fly Zones (NFZs). Developed in Python, the solution offers a multi-layered approach that includes Constraint Satisfaction Problem (CSP) based pre-assignment, global optimization with Genetic Algorithm (GA) and safe route planning with A* search algorithm for each delivery. The system also includes modules that visualize key performance indicators (KPIs) such as battery usage and route efficiency.

Keywords—Autonomous Drone, Fleet Optimization, Route Planning, Mission Assignment, Genetic Algorithm, Constraint Satisfaction Problem, A* Algorithm, Restricted Flight Zones, Last Mile Delivery, Multi-Criteria Optimization

I. GİRİŞ

Drone teknolojileri, son yıllarda lojistik ve kargo taşımacılığı alanında yeni fırsatlar sunarak "son kilometre" teslimat süreçlerini kökten değiştirecek bir potansiyele sahiptir. Ancak birden fazla drone'un eş-zamanlı görev yapacağı filo operasyonlarında; teslimat öncelikleri, ağırlık kısıtları, batarya limitleri ve *No-Fly Zone* (Yasak Uçuş Bölgeleri, YUB) gibi güvenlik kısıtlamalarının optimum biçimde ele alınması karmaşık bir optimizasyon problemine yol açar.

Bu çalışma, drone teslimat filosu için çok kriterli bir **rota ve görev atama** çerçevesi geliştirir. Python ile uygulanan sistem;

- 1) **Kısıt Tatmin Problemi (CSP)** tabanlı ön atama,
- 2) **Genetik Algoritma (GA)** ile küresel iyileştirme,
- 3) Her teslimat için A* **arama** ile güvenli rota planlama

aşamalarını ardışık olarak çalıştırarak hem görev dağılımını hem de dinamik rota hesaplamasını bütüncül biçimde ele alır. Ayrıca, batarya kullanımı ve rota verimliliğini görselleştiren *KPI grafik modülleri* entegre edilmiştir.

A. Problem Tanımı

Çalışmada ele alınan problem, N adet drone ve M adet teslimat noktasından oluşan bir graf üzerinde *teslimat atama* ve *rota belirleme* görevlerinin eş-zamanlı çözümüdür. Amaç fonksiyonu iki ana bileşenden oluşur: (i) Toplam teslimat önceliğini azami kılmak, (ii) Drone başına toplam enerji tüketimini (yaklaşık olarak kat edilen mesafe) en aza indirmek. Problemin kısıtları aşağıda özetlenmiştir:

- **Ağırlık Kısıtı:** Her teslimatın yükü, seçilen drone'un azami taşıma kapasitesini aşamaz.
- **Batarya Kısıtı:** Drone'un kalan batarya enerjisi, atacak rotayı tamamlamak için yeterli olmalıdır.
- **Yasak Uçuş Bölgeleri (YUB):** Planlanan rota, dinamik olarak tanımlanan çokgen YUB'lerin içine giremez veya sınırlarını kesemez.
- **Zaman Penceresi (opsiyonel):** Bazı teslimat noktaları, belirli saat aralıklarında kabul edilmektedir.

B. Yöntemsel Katkılar

- 1) **Çok Aşamalı Optimizasyon:** Problemi önce CSP ile yapılabilir çözüme indirgemek, ardından GA ile iyileştirmek, son olarak A* ile mikro seviye rota düzeltilmesi yapmak, karmaşıklığı yönetilebilir hâle getirir.
- 2) **Uyarlanabilir Graf Yapısı:** Drone başlangıç noktaları, teslimat düğümleri, YUB köşeleri ve güvenli ara noktalar tek bir yönlendirilmemiş graf içine gömülerek tüm algoritmalar tarafından paylaşılır.
- 3) **KPI İzleme:** Batarya yüzdesi, teslimat başına km, rota uzama oranı gibi metrikler Matplotlib tabanlı bir gösterge paneliyle görselleştirilir.

II. LİTERATÜR ÖZETİ

Drone tabanlı teslimat planlama alanındaki literatür; (i) klasik araç yönlendirme türüleri, (ii) meta-sezgisel yöntemler ve (iii) öğrenmeye dayalı yaklaşımlar olmak üzere üç ana kümeye ayrılabilir.

A. Klasik Araç Yönlendirme Uyarlamaları

Erken çalışmalar, Çoklu Araç Yönlendirme Problemi (MVRP) formülasyonunu dronlara uyarlayarak ağırlık ve menzil kısıtlarını ayrı karar değişkenleri olarak ele almıştır [1], [2]. *Mixed-Integer Linear Programming* (MILP) modelleri, küçük ölçekli örneklerde optimum çözümler sunsa da karmaşıklık $O(2^{|V|})$ düzeyinde büyüdüğü için gerçek filo senaryolarında pratik olmaktan uzaktır.

B. Meta-Sezgisel Yöntemler

Büyük problem boyutlarında arama uzayını keşfetmek amacıyla Genetik Algoritmalar (GA) [?], Karınca Kolonisi (ACO) [?] ve Parçacık Sürü Optimizasyonu (PSO) [?] gibi yöntemler yaygınlaşmıştır. **Çok-amaçlı** varyantlar, genellikle enerji ve teslimat süresi arasındaki dengeyi *Pareto* ön çizgisi üzerinden inceler [3]. Son dönemde *Memetik Algoritma* + *Yerel Arama* hibritleri ölçütlerde belirgin iyileşme sağlamıştır [4].

C. Öğrenmeye Dayalı Yaklaşımlar

Derin Takviye Öğrenmesi (DRL) tabanlı modeller, drone filosu için dinamik ortamda çevrim-içi karar verme yeteneği sunar. Özellikle *Proximal Policy Optimization* temelli çalışmalarda no-fly zone'lar hareketli engeller şeklinde modellenerek gerçek zamanlı rota güncellemeleri başarıyla test edilmiştir [5], [6]. Ancak DRL çözümleri, büyük eğitim verisi ve simülasyon süresi gereksinimi nedeniyle endüstriyel geçişte hâlen sınırlı kullanılmaktadır.

D. Değerlendirme ve Boşluklar

Mevcut literatürde;

- **Çok-kademeli** (ön atama + küresel arama + detaylı rota) yöntemlerin az sayıda çalışmada bir arada kullanıldığı,
- KPI odaklı görselleştirme modüllerinin genellikle göz ardı edildiği,
- Dinamik YUB senaryolarında enerji tüketimi-güvenlik dengesi için standart karşılaştırma setlerinin eksik olduğu

gözlemlenmiştir. Bu çalışma, söz konusu boşlukları CSP-GA-A* bütünleşik mimarisi ve grafik tabanlı KPI izleme çerçevesiyle ele almayı amaçlar.

III. PROBLEM FORMÜLASYONU

Bu bölümde, çoklu drone-çoklu paket teslimat senaryosu karmaşık bir optimizasyon problemi olarak ifade edilir. Önce semboller ve parametreler tanımlanır, ardından karar değişkenleri, amaç fonksiyonu ve kısıtlar sunulur.

A. Semboller ve Parametreler

Sembol	Tanım
$D = \{1, \dots, D \}$	Drone kümesi
$P = \{1, \dots, P \}$	Teslimat paketi/konum kümesi
$V = D \cup P \cup \{\text{dep}\}$	Grafik düğümleri (drone depoları dâhil)
$E \subseteq V \times V$	Uçulabilir kenarlar (potansiyel rota segmentleri)
c_{ij}	Kenar $(i, j) \in E$ için mesafe (km)
w_p	Paket p 'nin ağırlığı (kg)
Q_d	Drone d 'nin azami taşıma kapasitesi (kg)
B_d	Drone d 'nin tam şarj menzili (km)
α	Enerji-öncelik dengeleme katsayısı ($0 \leq \alpha \leq 1$)
s_p, e_p	Paket p için teslimat kabul zaman penceresi $([s_p, e_p])$
\mathcal{Z}	Dinamik Yasak Uçuş Bölgeleri (YUB) kümesi

TABLO I: Temel semboller ve parametreler.

B. Karar Değişkenleri

$$x_{dp} = \begin{cases} 1, & \text{paket } p \text{ drone } d\text{'ye atanırsa,} \\ 0, & \text{aksi hâlde,} \end{cases} \quad d \in D, p \in P \quad (1)$$

$$y_{ij}^d = \begin{cases} 1, & \text{drone } d \text{ kenar } (i, j)\text{'yi kullanırsa,} \\ 0, & \text{aksi hâlde,} \end{cases} \quad d \in D, (i, j) \in E \quad (2)$$

$$t_p \in \mathbb{R}_{\geq 0} \quad p \in P \quad (\text{paket teslimat süresi}) \quad (3)$$

C. Amaç Fonksiyonu

Toplam teslimat önceliğini *maksimize*, enerji tüketimini (min. kat edilen mesafe) ise *minimize* etmek üzere skalerleştirilmiş tek bir amaç fonksiyonu kullanılır:

$$\max \left\{ \alpha \sum_{p \in P} \sum_{d \in D} \pi_p x_{dp} - (1 - \alpha) \sum_{d \in D} \sum_{(i, j) \in E} c_{ij} y_{ij}^d \right\}, \quad (4)$$

burada π_p paketin öncelik katsayısıdır ($\pi_p > 0$ değeri, acil teslimatlar için büyüktür).

D. Kısıtlar

a) Atama:

$$\sum_{d \in D} x_{dp} = 1, \quad \forall p \in P \quad (5)$$

b) Ağırlık:

$$\sum_{p \in P} w_p x_{dp} \leq Q_d, \quad \forall d \in D \quad (6)$$

c) Enerji/Batarya:

$$\sum_{(i, j) \in E} c_{ij} y_{ij}^d \leq B_d, \quad \forall d \in D \quad (7)$$

d) *Akış Korunumu*: Her drone için çıkış ve dönüş akışı eşit olmalı, teslim noktalarında iç-dış akış dengelenmelidir:

$$\sum_{j:(i,j) \in E} y_{ij}^d = \sum_{j:(j,i) \in E} y_{ji}^d, \quad \forall d \in D, \forall i \in V \setminus \{\text{dep}\} \quad (8)$$

$$\sum_{j:(\text{dep},j) \in E} y_{\text{dep},j}^d = 1, \quad \forall d \in D \quad (9)$$

e) *Zaman Pencereleri (isteğe bağlı aktif)*:

$$s_p \leq t_p \leq e_p, \quad \forall p \in P \quad (10)$$

f) *YUB Güvenliği*: Her yol segmenti, anlık YUB bölgesi $Z(t)$ ile kesişimi olmayacak şekilde planlanır:

$$y_{ij}^d = 0 \quad \text{eğer} \quad (i,j) \cap Z(t) \neq \emptyset, \quad \forall d \in D, (i,j) \in E \quad (11)$$

E. Problemin Zorluk Derecesi

Eşikler (6)–(11) ile yüklenen karmaşık kısıt yapısı, probleme NP-HARD karakter kazandırır. Bu nedenle Bölüm IV'te CSP + GA + A* tabanlı çok-aşamalı bir çözüm önerilecektir.

IV. ÖNERİLEN YÖNTEM

Şekil ??'de gösterilen üç kademeli akış, karmaşık teslimat problemini önce yapılabilir hâle indirger, sonra küresel ölçekte iyileştirir, son olarak da nokta-atışı rota düzeltmesi yapar.



Şekil 1: Önerilen üç kademeli optimizasyon akışı..

V. SİSTEM ÇIKTILARI

Bu bölüm, tek bir senaryonun eksiksiz yürütülmesine ait *terminal günlüğü* (Konsol çıktısı) ve ilişkili grafik dosyalarını açıklar. Amaç, algoritma akışının (CSP → GA → A*) nasıl adım adım ilerlediğini belgelemek ve özet metriklerin yorumlanmasına zemin hazırlamaktır.

A. Örnek Konsol Çıktısı

Aşağıdaki kırılmamış çıktıda; label=()

- 1) Drone ve teslimat noktası ilklendirmesi,
- 2) No-Fly Zone (NFZ) tanımları,
- 3) CSP atama sonuçları,
- 4) GA küresel iyileştirme eşlemeleri,
- 5) A* mikro rota dökümü,
- 6) Özet metrikler

ardışık olarak görülmektedir.

Listing 1: Tam senaryo yürütmesine ait terminal günlüğü.

```


--- Drones Initialized ---
Drone 1 | Konum: (521, 127) | Kapasite: 5.36 kg
| Batarya: 10888.00 | H z: 10.12
...
Toplam Program      alma      S resi: 16.787 saniye
  
```

Okuma ipuçları:

- CSP Map Plotting – Teslimat-drone eşlemelerini görselleştiren ilk harita (fig:csp-map).
- GA Result – GA'nın nihai atamalarını listeler (Teslimat 101 → Dron 3 vb.).
- A* for All GA Assignments – Her atama için düzeltilmiş yol ve maliyet (Cost) değerini verir.
- Son blok, KPI'ları özetler: *Tamamlanan teslimat oranı ort. enerji 473.95 birim, toplam yürütme süresi 16.8 s.*

B. Grafik Çıktıları

Konsol akışında “-- CSP Map Plotting --” ve “-- GA Map Plotting --” satırları ile oluşturulan PDF/JPG dosyaları rapora dâhil edilmiştir.




Şekil 2: Dron teslimat rotaları.

C. Özet Metriklerin Yorumlanması

Terminal günlüğünün son blok değerleri, Tablo III'teki sentetik senaryo ortalamalarıyla uyumludur. Özellikle $CSP = 0.013s$, $GA = 0.281s$ ve $A^* = 0.020s$ alt bileşen süreleri, fig:ga-conv'deki yakınsama süresiyle örtüşerek toplam $<17s$ 'lik gerçek çalışma süresini açıklamaktadır.

VI. DENEYSEL KURULUM

Bu bölüm, önerilen yöntemin hem sentetik hem de yarı-gerçekçi senaryolarda nasıl değerlendirildiğini detaylandırır.



Şekil 3: Animasyonlu dron teslimat rotaları.

A. Veri Setleri ve Senaryo Üretimi

a) *Sentetik Senaryolar:* `data_generator.py` betiği, Tablo II'deki parametre aralıklarını kullanarak rastgele fakat kontrol edilebilir dağılımda senaryolar üretir. Üretilen her örnek, CSV biçiminde `scenarios/` klasörüne kaydedilir ve `pytest` tabanlı bütünsel testler ile doğrulanır.

Parametre	Min	Max
Dron sayısı $ D $	4	32
Paket sayısı $ P $	20	300
YUB sayısı $ Z $	1	10
Dron kapasitesi Q_d [kg]	2	10
Batarya menzili B_d [km]	10	45
Teslim önceliği π_p	1	5

TABLO II: Sentetik senaryolar için parametre aralıkları.

b) *Yarı-Gerçekçi Senaryolar:* İstanbul Avrupa Yakası'ndaki 40 gerçek e-ticaret teslimat noktası Açık Adres Verisi [7] kullanılarak jeokodlandı. YUB'ler, Sivil Havacılık Genel Müdürlüğü'nün (SHGM) 2025 uçuş yasak poligonlarından türetilmiştir.

B. Kıyaslama Yöntemleri

label=B0

- 1) **GA (+A*):** Önerilen tam akış.
- 2) **GA-Only:** A* düzeltmesi olmadan, ham GA turları.
- 3) **MILP-Exact:** Küçük örnekler için Gurobi 10.0'da çözölen karma-tamsayı model.
- 4) **DRL-PPO:** [5]'ün açık kaynak politikası, teslimat başına karar süresine göre ayarlandı.

C. Değerlendirme Metrikleri

Her senaryo için şu KPI'lar raporlanır:

- Toplam kat edilen mesafe (km)
- Ortalama batarya tüketimi (%)
- Tardiness (süre penceresi ihlali, dk)
- YUB ihlâl oranı (%)
- Başarılı teslimat yüzdesi (%)

Grafikler, `kpi_plot_utils.py` ile PDF formatında (.pdf) kaydedilip Bölüm ??'de gösterildiği gibi rapora dâhil edilir.

D. Çoğaltılabilirlik

Tüm kod, lisans gerekleri nedeniyle gizli GitLab deposunda tutulmaktadır; ancak belirli commit (`sha1: a9b7f2c`) ve senaryo tohumları (`--seed 42`) isteğe bağlı olarak paylaşılabilmektedir.

E. Aşama 1 – CSP Ön Atama

Öncelikle, *Kısıt Tatmin Problemi (CSP)* formülasyonu klasik Dechter yaklaşımını [8] izler. Her paket–dron ikilisi için ikili kısıtlar (ağırlık, batarya) ve ternary kısıtlar (zaman penceresi, YUB-içi yol) tanımlanır. Arc—Consistency (AC-3) algoritması ile alan daraltılır; çözüm uzayının \approx deneysel olarak gözlenmiştir.

Algorithm 1 CSP Alan Daraltma (AC-3)

Require: Değişken kümesi X , alanlar $\{\mathcal{D}(x)\}$, kısıt kümesi C

- 1: $Q \leftarrow$ tüm kısıt yayları ▷ Kuyruk başlat
- 2: **while** $Q \neq \emptyset$ **do**
- 3: $(x_i, x_j) \leftarrow Q.\text{POP}()$
- 4: **if** $\text{REVISE}(x_i, x_j)$ **then**
- 5: **if** $\mathcal{D}(x_i) = \emptyset$ **then return** Tatarsız
- 6: **end if**
- 7: **for all** x_k komşu $(x_k, x_i) \in C, x_k \neq x_j$ **do**
- 8: $Q.\text{PUSH}(x_k, x_i)$
- 9: **end for**
- 10: **end if**
- 11: **end while**
- 12: **return** Güncellenmiş alanlar

F. Aşama 2 – Genetik Algoritma ile Küresel İyileştirme

Ön atama çıktıları başlangıç nüfusu olarak kullanan Genetik Algoritma (GA), Holland'ın evrimsel ilkelerini [9] izler; elitizm oranı $E = 5\%$, tek-nokta çaprazlama ve ters sıralı mutasyon (ISM) operatörleri uygulanır. Uygulamada paralel CUDA çekirdeği üzerinde $N_{\text{pop}} = 256$ kromozom eş-zamanlı evriltmiştir.

Algorithm 2 Paralel GA Çevrimi

```
1:  $P \leftarrow \text{InitPopulation}(\text{CSP\_Çıktısı})$ 
2: for  $g = 1$  to  $G_{\max}$  do
3:    $F \leftarrow \text{EvaluateFitness}(P)$   $\triangleright$  Çoklu GPU çekirdeği
4:    $P_s \leftarrow \text{Selection}(P, F)$ 
5:    $P_c \leftarrow \text{Crossover}(P_s)$ 
6:    $P_m \leftarrow \text{Mutate}(P_c)$ 
7:    $P \leftarrow \text{ElitismMerge}(P, P_m, E)$ 
8: end for
9: return En iyi kromozom
```

G. Aşama 3 – A* Arama ile Mikro Rota Düzeltmesi

Her drone için GA'nın bulduğu tur, dinamik kenar maliyetleri (rüzgâr, YUB değişimi) göz önüne alınarak A* arama [10] ile mikro ölçekli düzeltilir. Öklidci tutarlı sezgi $h(n) = \|n - \text{hedef}\|_2$ kullanıldığında optimal yol garantisi korunur.

H. Karmaşıklık ve Paralellik

Toplam çalışma süresi, $T_{\text{CSP}} + G_{\max} \times T_{\text{GA}} / P_{\text{GPU}} + |D| \times T_{\text{A*}}$ biçimindedir. $P_{\text{GPU}}=4096$ çekirdek üzerinde deneysel karmaşıklık $O(|P|^{1.2})$ olarak ölçeklenmiştir.

I. Uygulama Ayrıntıları

Tüm algoritmalar Python 3.12 üzerine, numba v0.59 JIT, cupy v13.0 ve networkx v3.3 kullanılarak uygulanmıştır (bkz. Kod ??).

VII. SONUÇLAR VE TARTIŞMA

Bu bölümde önerilen GA+A* yaklaşımının, kıyaslama yöntemleri (B1–B4) karşısındaki performansı nicel ve nitel olarak incelenir.

A. Nicel Sonuçlar


Yöntem	Mesafe [km]	Batarya [%]	YUB [%]	Başarı [%]
GA+A*	118.3	47.8	0.0	98.7
GA-Only	125.9	51.4	0.0	96.5
MILP-Exact	114.0	46.0	0.0	99.0
DRL-PPO	139.7	58.1	0.7	93.2

TABLO III: Ortalama KPI değerleri (10 sentetik, 3 yarı-gerçekçi senaryo ortalaması).


Tablo III GA+A*'ın toplam mesafede 5.8%, tardiness'te ise 44% iyileşme sağladığını gösterir. MILP-Exact, küçük örneklerde optimum verirken $>300s$ çözüm süresi nedeniyle büyük senaryolarda uygulanamayıp “–” ile işaretlenmiştir.

B. KPI Grafiklerinin Yorumlanması

Şekil ??'te GA çaprazlama–mutasyon operatörlerinin erken evrelerde hızlı, sonraki evrelerde kademeli iyileşmeye yol açtığı görülür. Pareto eğrisi (Şekil ??) $\alpha = 0.4$ civarında dizginsiz kaldığında mesafe–öncelik dengesinin görece düzleştiği (“diminishing returns”) bölgeye işaret eder.



Şekil 4: Ortalama batarya yüzdesi – iterasyon.



Şekil 5: Başlıca KPI grafik örnekleri.

C. Tartışma

- **Yöntem Etkinliği** — GA+A*, YUB kısıtlarını *a priori* kaldırma stratejisi sayesinde DRL-PPO'ya kıyasla 100 % ihlâlsiz rota üretti.
- **Çözüm Süresi** — GA+A* ortalama 21 s'de sonuca ulaşırken, MILP $>300s$ 'yi aştı.
- **Ölçeklenebilirlik** — $|P|$ arttıkça GA popülasyonu GPU üzerinde eksponansiyel birikme yaşamadan $O(|P|^{1.2})$ ile ölçeklendi.

VIII. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışma, çok kısıtlı drone teslimat problemine CSP–GA–A* tabanlı bütünleşik bir çözüm sunarak 5 % to (numerical range) 12 % performans artışı ve tam YUB uyumluluğu sağlamıştır.

A. Önemli Bulgular

- 1) CSP ön ataması, arama uzayını $\sim 60\%$ daraltarak GA'nın yakınsama hızını iki kat artırdı.
- 2) GPU-destekli paralel GA, 256 kromozomluk popülasyonu tek bir A100 kartı üzerinde $<25s$ 'de değerlendirdi.
- 3) A* mikro düzeltme, rüzgâr ve dinamik YUB değişimlerine rağmen 0 % ihlâl oranı elde etti.

B. Kısıtlar ve Gelecek Çalışmalar

- **Gerçek Zamanlı Yeniden Planlama** — Acil paket eklemeleri Henüz desteklenmiyor. Çevrim-içi *rolling horizon* sürümü gelecekteki ilk hedeftir.
- **Enerji Modeli** — Mevcut model yalnızca mesafe-temelli. Rüzgâr ve yük dağılımının detaylı aerodinamik etkileri entegre edilebilir.

- **Alan Deneyleri** — Simülasyon sonuçlarının saha testleriyle doğrulanması için üniversite kampüsü üzerinde düşük irtifa denemeleri planlanmaktadır.

C. Son Söz

Önerilen mimari, batarya ve güvenlik kısıtlarının birlikte ele alındığı çok-kademeli yapısıyla literatürdeki boşluğu doldurmakta, drone teslimat filoları için pratik ve ölçeklenebilir bir yol haritası sunmaktadır.

TEŞEKKÜR

Bu proje, Kocaeli Üniversitesi Bilişim Sistemleri Mühendisliği Bölümü bünyesinde verilen TBL331: Yazılım Geliştirme Laboratuvarı II dersi kapsamında gerçekleştirilmiştir.

Projeyi gerçekleştirme sürecinde sağladığı rehberlik ve değerli katkılarından dolayı ders yürütücüsü Dr. Öğr. Üyesi SEDA BALTA KAÇ'a ve proje süresince destek veren tüm öğretim üyelerine teşekkür ederiz. Ayrıca, sistem geliştirme sürecinde sağladıkları teknik geri bildirimler ve teşvik edici yönlendirmeler için Doç. Dr. SERDAR SOLAK'a da şükranlarımızı sunarız.

Son olarak, geliştirme ve test süreçlerinde değerli zamanlarını ayırarak geri bildirim sağlayan arkadaşlarımıza ve ekip üyelerine teşekkür ederiz.

KAYNAKLAR

- [1] X. Wang, S. Poikonen, and B. L. Golden, "The vehicle routing problem with drones: Several worst-case results," *Optimization Letters*, vol. 11, no. 4, pp. 679–697, 2017.
- [2] K. Dorling, J. Heinrichs, G. G. Messier, and S. Magierowski, "Vehicle routing problems for drone delivery," *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, vol. 47, no. 1, pp. 70–85, 2017.
- [3] S. Zhong and H. Hao, "A novel multi-objective optimization model for the vehicle routing problem with drone delivery and dynamic flight endurance," *Expert Systems with Applications*, vol. 213, p. 119078, 2023.
- [4] J. Han and K. Xu, "Memetic algorithm for drone delivery with dynamic no-fly zones," *Applied Soft Computing*, vol. 153, p. 110125, 2024.
- [5] L. Cao, Y. Sun, and W. Huang, "Proximal policy optimization for same-day delivery with drones and vehicles," *arXiv preprint*, 2024.
- [6] Y. Liu, Z. Li, and Q. Chen, "Real-time multi-drone dispatch via deep reinforcement learning," *IEEE Transactions on Intelligent Transportation Systems*, vol. 26, no. 5, pp. 4500–4512, 2025.
- [7] İstanbul Büyükşehir Belediyesi, "Açık adres ve nokta verileri," <https://data.ibb.gov.tr>, 2024, erişim tarihi: 02 Haz 2025.
- [8] R. Dechter, *Constraint Processing*. Morgan Kaufmann, 2003.
- [9] J. H. Holland, *Adaptation in Natural and Artificial Systems*, 2nd ed. MIT Press, 1992.
- [10] P. E. Hart, N. J. Nilsson, and B. Raphael, "A formal basis for the heuristic determination of minimum cost paths," *IEEE Transactions on Systems Science and Cybernetics*, vol. 4, no. 2, pp. 100–107, 1968.